PROYECTO INTEGRADOR · LCD301

E-commerce: ventas, devoluciones y clientes

Grupo A | Informe técnico y resultados

Una plataforma reproducible que recibe eventos REST y un catálogo CSV, valida su calidad, procesa lotes con Spark y publica hechos financieros en PostgreSQL. Dos paneles permiten explorar el negocio y observar el funcionamiento del sistema.



Resultado comprobado	Valor
Eventos publicados después del lote incremental	31,007
Ingreso neto final	26.381.649,45 BOB
Lote incremental	7 eventos nuevos · +280,00 BOB netos
Control de repetición	Cero hechos nuevos al repetir BASE

Datos sintéticos con semilla 301; período abril-septiembre de 2026. Estas cifras describen la simulación académica, no una empresa real.

1. Fuentes, ingesta y calidad

Dos fuentes diferentes llegan al mismo flujo. La API entrega un sobre paginado y determinista de eventos; NiFi separa sus elementos. El catálogo llega como archivo CSV batch y describe 100 productos.

Contrato	Definición
Identidades	event_id único; order_id, customer_id y order_line_id estables.
Dinero	Enteros en centavos BOB. Los descuentos se expresan por línea completa.
Tiempo	event_time de negocio en UTC; ingested_at asignado por NiFi.
Eventos	created, paid, cancelled y refunded; devoluciones referencian el pago original.
Catálogo	product_id, name, category, active, catalog_version, list_price_cents. Sin comas en los textos según contrato CSV del laboratorio.

Calidad en capas

ValidateJson aplica el contrato JSON Schema antes de añadir metadatos. El script Groovy comprueba cabecera, campos, SKU repetidos, estado y precio del catálogo. Los errores conservan el contenido original y un diagnóstico en data/quality/ingesta. Spark y la publicación validan además catálogo, importes y ciclo del pedido.

Entradas BASE	Cantidad prevista / reconciliada
Objetos enviados por API	31.065
Eventos estructuralmente inválidos	20
Duplicados deliberados	25
Eventos inválidos de negocio o pendientes	20
Eventos válidos publicados	31.000
CSV de prueba rechazado	1 archivo

La API limita solicitudes; NiFi configura backpressure por cola, conserva FlowFiles y dispone de reintentos acotados ante errores de transporte. La evidencia de configuración y la prueba de presión están en 03_Visualizaciones/evidencias. Un lote solo se procesa cuando su manifiesto está cerrado.

2. Procesamiento y reglas financieras

Apache Spark 4.0.1 lee JSONL y CSV con esquemas explícitos. Normaliza canal y categoría, convierte fechas, detecta duplicados/conflictos, une el catálogo sin perder SKU desconocidos y separa registros de calidad. Calcula agregados candidatos por día, canal y categoría y enruta pagos de alto valor a una salida de alertas.

Publicación confiable

Spark escribe staging mediante JDBC. Una transacción SQL valida la secuencia del pedido y publica registro, hechos, líneas, pendientes y contadores. Un bloqueo asesor serializa esta publicación. El registro global evita repetir un evento, incluso si su devolución cruza el límite de mes.

Evento	Regla y efecto sobre el ingreso
created	Debe existir una sola creación; registra el pedido y no reconoce ingreso.
paid	Requiere creación compatible y un único pago por pedido. Suma el importe confirmado.
cancelled	Solo para pedidos impagos. Importe reconocido cero.
refunded	Requiere pago y línea originales; cantidad e importe acumulados no pueden superar la compra. Resta el reembolso.

Descuentos, historia y datos tardíos

Se conserva el precio, la categoría y la versión del catálogo de la compra. La devolución distribuye el neto descontado en centavos y permite recuperar el centavo de redondeo en la última unidad. Si falta un antecedente, el evento se conserva en pending_event y se reintenta posteriormente; no genera ingresos mientras está pendiente.

Al repetir BASE se publican cero hechos nuevos. Las salidas candidate_* de Spark son anteriores a la validación del ciclo; los KPIs de los paneles se calculan sobre hechos publicados en PostgreSQL. El procesamiento es batch; no requiere ventanas de streaming. La actualización del panel cada 15 segundos muestra los nuevos lotes después de su publicación.

Prueba aislada Spark + JDBC

Seis eventos de control produjeron tres publicados, dos rechazos y un duplicado. La prueba comprobó normalización, SKU desconocido, cantidad inválida, precio histórico e ingreso neto de 5.000 centavos. Existe evidencia JSON y una prueba transaccional separada de fallo/rollback.

3. Almacenamiento y recuperación

PostgreSQL 17.6 es el almacenamiento primario. El esquema ecommerce combina dimensiones de productos/clientes, registro único global, hechos de evento y hechos por línea. Conserva las fuentes sintéticas y archivos landing para permitir reprocesamiento y auditoría.

Objeto	Propósito
event_registry	Identidad y huella del evento; unicidad global y referencias.
fact_event / fact_event_line	Hechos financieros particionados por mes UTC; claves incluyen event_month.
dim_product / dim_customer	Catálogo actualizado e identidad del cliente sintético.
quality_reject / pending_event	Rechazos explicados y eventos que esperan antecedentes.
pipeline_runs / system_metric	Duración, throughput, latencia, colas y errores.
Vistas v_*	Consultas de ventas, pedidos, clientes y operación.

Particionamiento e índices

Las particiones mensuales se crean al publicar los meses correspondientes. Los índices de fecha/canal, pedido, producto y pago original sirven al acceso del caso de uso. Las seis consultas utilizan límites de fecha; los planes EXPLAIN permiten inspeccionar la lectura real sin atribuir mejoras no medidas.

Backup restaurado y verificado

Se produjo un respaldo pg_dump de formato custom de 12,982,037 bytes y se restauró en una base aislada. Ocho tablas de negocio y control coincidieron en conteos y SHA256 de filas ordenadas; también coincidieron pedidos pagados e ingreso neto. El script conserva las siete copias más recientes que él mismo creó.

La comparación de ocho tablas no incluye system_metric: el dump también la contiene, pero el muestreo puede continuar durante la verificación. El respaldo entregado tiene huella de archivo en restore_verification.json. La prueba no sobrescribe la base principal. No se implementó réplica ni alta disponibilidad.

Principios de operación

Un solo job publica cada lote; se conservan los archivos y manifiestos inmutables. No eliminar cuarentena para ocultar errores. Una recuperación restaura en una base nueva, compara resultados y cambia la conexión solo después de validar. Credenciales de laboratorio se configuran por variables y no se exporta el token de NiFi.

4. Seis análisis y su rendimiento

Cada consulta responde una pregunta de negocio y conserva su resultado, plan y medición. El período analizado es [1 de abril, 1 de octubre de 2026), con corte de observación 1 de octubre UTC.

Consulta / pregunta de negocio	Mediana cliente (ms)	Filas
Q1 Ingreso por día y canal	37,91	536
Q2 Productos líderes por categoría	126,83	100
Q3 Ticket promedio por canal	28,85	3
Q4 Cancelaciones por cohorte	32,70	18
Q5 Devolución a 30 días	192,49	100
Q6 Valor y repetición de clientes	31,66	1000

Interpretación de las tasas

Q4 divide pedidos cancelados sin pago entre pedidos creados por cohorte. Q5 usa unidades de pagos que disponen de 30 días completos hasta el corte y cuenta solo devoluciones dentro de esos 30 días. Esto evita penalizar compras recientes cuyo período de devolución sigue abierto. Q6 calcula valor neto observado y repetición; no estima CLV futuro ni abandono de carrito.

Metodología de medición

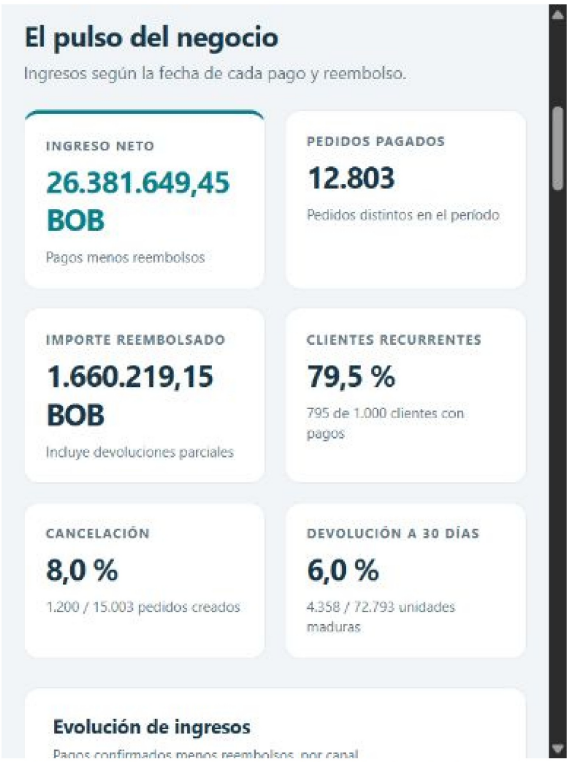
Se ejecutó ANALYZE y se midió una primera ejecución más cinco repeticiones consecutivas por consulta. La tabla muestra la mediana del cliente, que incluye el viaje a PostgreSQL y la recuperación del resultado. EXPLAIN (ANALYZE, BUFFERS, FORMAT JSON) conserva planificación y ejecución del servidor por separado.

La primera medición no garantiza caché fría. Los resultados corresponden a este equipo y volumen sintético; no son una garantía para producción. No se comparó un diseño anterior sin índices. Las cifras completas y los planes están en data/evidence/benchmark.

Decisiones que permiten tomar

- Asignar campañas e inventario según ingreso, demanda y reembolsos por canal/categoría.
- Investigar productos con devolución elevada usando cohortes comparables.
- Explorar clientes recurrentes y su valor neto dentro del período observado.

5. Visualización de negocio



Captura real del dashboard conectado a PostgreSQL, posterior a la publicación. Las imágenes completas y capturas de interacción están en 03_Visualizaciones/capturas.

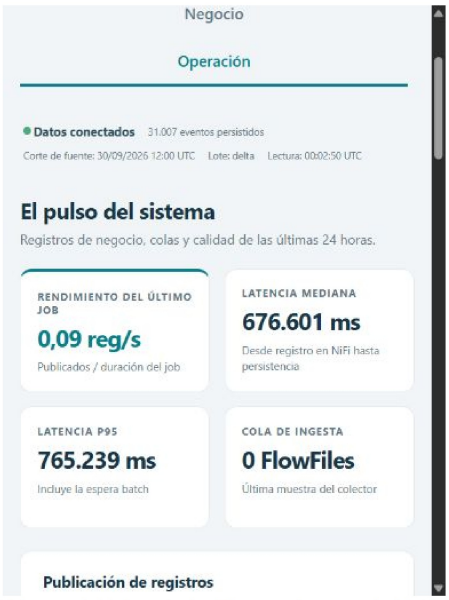
Tipo de visualización	Pregunta
Líneas	¿Cómo evoluciona el ingreso neto por canal?
Barras	¿Qué categorías y productos tienen más unidades pagadas?
Mapa de calor	¿En qué horas y días se confirman pagos?
Donut	¿Cómo se reparte la participación de canales?
Dispersión	¿Cómo se relacionan frecuencia y valor de clientes?
Histograma	¿Cómo se distribuye el importe de los tickets?

Interactividad

Filtros de período, canal y categoría; navegación categoría → producto → pedido → historial de eventos. El panel lee PostgreSQL cada 15 segundos. BASE y DELTA permiten demostrar actualización con siete eventos nuevos y 280,00 BOB adicionales, conservando el estado de los hechos históricos.

La tabla de un producto presenta su subtotal; el historial presenta el pedido completo. La tasa de devolución del panel usa el último evento como corte, mientras Q5 usa 1 de octubre UTC; ambas muestran su corte para comparar cohortes correctamente.

6. Operación y aceptación



Panel operacional: métricas de las últimas 24 horas del laboratorio. Tiempo de negocio histórico y latencia de sistema tienen definiciones distintas.

Métricas observadas

Throughput en registros por segundo de cada job, duración y resultado de intentos, latencia mediana/p95 desde el registro individual en NiFi hasta la persistencia y colas/errores. ingested_at se fija después de SplitJson: incluye validación, preparación/espera batch y procesamiento, y excluye la descarga HTTP y las colas anteriores. mtime es solo fallback documentado. Los pendientes se muestran separados de los rechazos.

Control real	Resultado
Fuentes y API	Contrato, ciclo de pedidos y nueve verificaciones HTTP: PASS.
Negocio y transacción	Reglas financieras, rollback y repetición: PASS.
Spark real + JDBC	Lecturas, transformaciones, unión y publicación: PASS.
PostgreSQL completo	Conteos y todos los KPIs contra expected.json: PASS.
Dashboard	Callbacks, consultas, filtros, tipos de gráficos y detalle: PASS.
Backup / restauración	Ocho tablas y cifras financieras coincidentes: PASS.

BASE: 31,000 hechos, neto 26.381.369,45 BOB. Final: 31,007 hechos, neto 26.381.649,45 BOB. La diferencia es exactamente el lote incremental previsto.