PROYECTO INTEGRADOR · LCD301

# E-commerce: ventas, devoluciones y clientes

## Grupo A | Informe técnico y resultados

Una plataforma reproducible que recibe eventos REST y un catálogo CSV, valida su calidad, procesa lotes con Spark y publica hechos financieros en PostgreSQL. Dos paneles permiten explorar el negocio y observar el funcionamiento del sistema.




| Resultado comprobado | Valor |
|---|---|
| Eventos publicados después del lote incremental | 31,007 |
| Ingreso neto final | 26.381.649,45 BOB |
| Lote incremental | 7 eventos nuevos · +280,00 BOB netos |
| Control de repetición | Cero hechos nuevos al repetir BASE |

Datos sintéticos con semilla 301; período abril-septiembre de 2026. Estas cifras describen la simulación académica, no una empresa real.

# 1. Fuentes, ingesta y calidad

Dos fuentes diferentes llegan al mismo flujo. La API entrega un sobre paginado y determinista de eventos; NiFi separa sus elementos. El catálogo llega como archivo CSV batch y describe 100 productos.

| Contrato | Definición |
|---|---|
| Identidades | event_id único; order_id, customer_id y order_line_id estables. |
| Dinero | Enteros en centavos BOB. Los descuentos se expresan por línea completa. |
| Tiempo | event_time de negocio en UTC; ingested_at asignado por NiFi. |
| Eventos | created, paid, cancelled y refunded; devoluciones referencian el pago original. |
| Catálogo | product_id, name, category, active, catalog_version, list_price_cents. Sin comas en los textos según contrato CSV del laboratorio. |

## Calidad en capas

ValidateJson aplica el contrato JSON Schema antes de añadir metadatos. El script Groovy comprueba cabecera, campos, SKU repetidos, estado y precio del catálogo. Los errores conservan el contenido original y un diagnóstico en data/quality/ingesta. Spark y la publicación validan además catálogo, importes y ciclo del pedido.

| Entradas BASE | Cantidad prevista / reconciliada |
|---|---|
| Objetos enviados por API | 31.065 |
| Eventos estructuralmente inválidos | 20 |
| Duplicados deliberados | 25 |
| Eventos inválidos de negocio o pendientes | 20 |
| Eventos válidos publicados | 31.000 |
| CSV de prueba rechazado | 1 archivo |

La API limita solicitudes; NiFi configura backpressure por cola, conserva FlowFiles y dispone de reintentos acotados ante errores de transporte. La evidencia de configuración y la prueba de presión están en 03_Visualizaciones/evidencias. Un lote solo se procesa cuando su manifiesto está cerrado.

# 2. Procesamiento y reglas financieras

Apache Spark 4.0.1 lee JSONL y CSV con esquemas explícitos. Normaliza canal y categoría, convierte fechas, detecta duplicados/conflictos, une el catálogo sin perder SKU desconocidos y separa registros de calidad. Calcula agregados candidatos por día, canal y categoría y enruta pagos de alto valor a una salida de alertas.

## Publicación confiable

Spark escribe staging mediante JDBC. Una transacción SQL valida la secuencia del pedido y publica registro, hechos, líneas, pendientes y contadores. Un bloqueo asesor serializa esta publicación. El registro global evita repetir un evento, incluso si su devolución cruza el límite de mes.

| Evento | Regla y efecto sobre el ingreso |
|---|---|
| created | Debe existir una sola creación; registra el pedido y no reconoce ingreso. |
| paid | Requiere creación compatible y un único pago por pedido. Suma el importe confirmado. |
| cancelled | Solo para pedidos impagos. Importe reconocido cero. |
| refunded | Requiere pago y línea originales; cantidad e importe acumulados no pueden superar la compra. Resta el reembolso. |

## Descuentos, historia y datos tardíos

Se conserva el precio, la categoría y la versión del catálogo de la compra. La devolución distribuye el neto descontado en centavos y permite recuperar el centavo de redondeo en la última unidad. Si falta un antecedente, el evento se conserva en pending_event y se reintenta posteriormente; no genera ingresos mientras está pendiente.

Al repetir BASE se publican cero hechos nuevos. Las salidas candidate_* de Spark son anteriores a la validación del ciclo; los KPIs de los paneles se calculan sobre hechos publicados en PostgreSQL. El procesamiento es batch; no requiere ventanas de streaming. La actualización del panel cada 15 segundos muestra los nuevos lotes después de su publicación.

## Prueba aislada Spark + JDBC

Seis eventos de control produjeron tres publicados, dos rechazos y un duplicado. La prueba comprobó normalización, SKU desconocido, cantidad inválida, precio histórico e ingreso neto de 5.000 centavos. Existe evidencia JSON y una prueba transaccional separada de fallo/rollback.

# 3. Almacenamiento y recuperación

PostgreSQL 17.6 es el almacenamiento primario. El esquema ecommerce combina dimensiones de productos/clientes, registro único global, hechos de evento y hechos por línea. Conserva las fuentes sintéticas y archivos landing para permitir reprocesamiento y auditoría.

| Objeto | Propósito |
|---|---|
| event_registry | Identidad y huella del evento; unicidad global y referencias. |
| fact_event / fact_event_line | Hechos financieros particionados por mes UTC; claves incluyen event_month. |
| dim_product / dim_customer | Catálogo actualizado e identidad del cliente sintético. |
| quality_reject / pending_event | Rechazos explicados y eventos que esperan antecedentes. |
| pipeline_runs / system_metric | Duración, throughput, latencia, colas y errores. |
| Vistas v_* | Consultas de ventas, pedidos, clientes y operación. |

## Particionamiento e índices

Las particiones mensuales se crean al publicar los meses correspondientes. Los índices de fecha/canal, pedido, producto y pago original sirven al acceso del caso de uso. Las seis consultas utilizan límites de fecha; los planes EXPLAIN permiten inspeccionar la lectura real sin atribuir mejoras no medidas.

## Backup restaurado y verificado

Se produjo un respaldo pg_dump de formato custom de 12,982,037 bytes y se restauró en una base aislada. Ocho tablas de negocio y control coincidieron en conteos y SHA256 de filas ordenadas; también coincidieron pedidos pagados e ingreso neto. El script conserva las siete copias más recientes que él mismo creó.

La comparación de ocho tablas no incluye system_metric: el dump también la contiene, pero el muestreo puede continuar durante la verificación. El respaldo entregado tiene huella de archivo en restore_verification.json. La prueba no sobrescribe la base principal. No se implementó réplica ni alta disponibilidad.

## Principios de operación

Un solo job publica cada lote; se conservan los archivos y manifiestos inmutables. No eliminar cuarentena para ocultar errores. Una recuperación restaura en una base nueva, compara resultados y cambia la conexión solo después de validar. Credenciales de laboratorio se configuran por variables y no se exporta el token de NiFi.

# 4. Seis análisis y su rendimiento

Cada consulta responde una pregunta de negocio y conserva su resultado, plan y medición. El período analizado es [1 de abril, 1 de octubre de 2026), con corte de observación 1 de octubre UTC.

| Consulta / pregunta de negocio | Mediana cliente (ms) | Filas |
|---|---|---|
| Q1 Ingreso por día y canal | 37,91 | 536 |
| Q2 Productos líderes por categoría | 126,83 | 100 |
| Q3 Ticket promedio por canal | 28,85 | 3 |
| Q4 Cancelaciones por cohorte | 32,70 | 18 |
| Q5 Devolución a 30 días | 192,49 | 100 |
| Q6 Valor y repetición de clientes | 31,66 | 1000 |

## Interpretación de las tasas

Q4 divide pedidos cancelados sin pago entre pedidos creados por cohorte. Q5 usa unidades de pagos que disponen de 30 días completos hasta el corte y cuenta solo devoluciones dentro de esos 30 días. Esto evita penalizar compras recientes cuyo período de devolución sigue abierto. Q6 calcula valor neto observado y repetición; no estima CLV futuro ni abandono de carrito.

## Metodología de medición

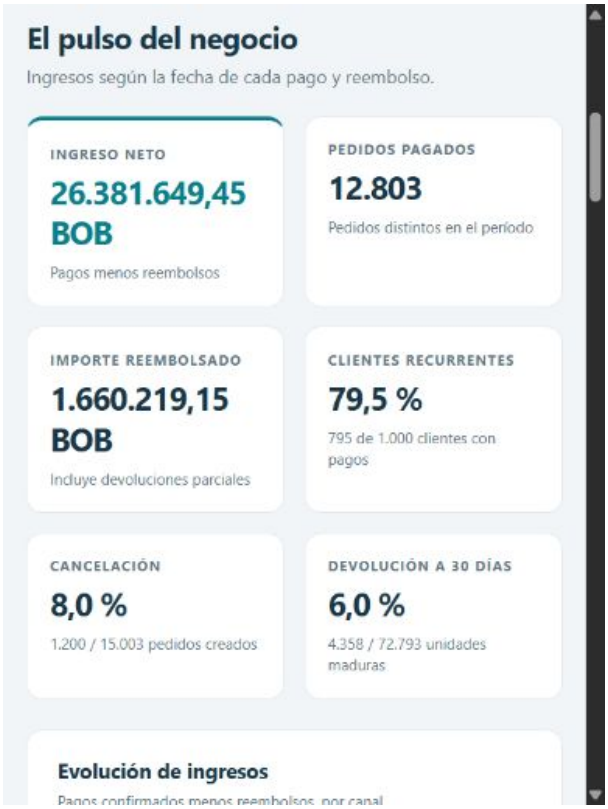
Se ejecutó ANALYZE y se midió una primera ejecución más cinco repeticiones consecutivas por consulta. La tabla muestra la mediana del cliente, que incluye el viaje a PostgreSQL y la recuperación del resultado. EXPLAIN (ANALYZE, BUFFERS, FORMAT JSON) conserva planificación y ejecución del servidor por separado.

La primera medición no garantiza caché fría. Los resultados corresponden a este equipo y volumen sintético; no son una garantía para producción. No se comparó un diseño anterior sin índices. Las cifras completas y los planes están en data/evidence/benchmark.

## Decisiones que permiten tomar

- Asignar campañas e inventario según ingreso, demanda y reembolsos por canal/categoría.
- Investigar productos con devolución elevada usando cohortes comparables.
- Explorar clientes recurrentes y su valor neto dentro del período observado.

# 5. Visualización de negocio




Captura real del dashboard conectado a PostgreSQL, posterior a la publicación. Las imágenes completas y capturas de interacción están en 03_Visualizaciones/capturas.

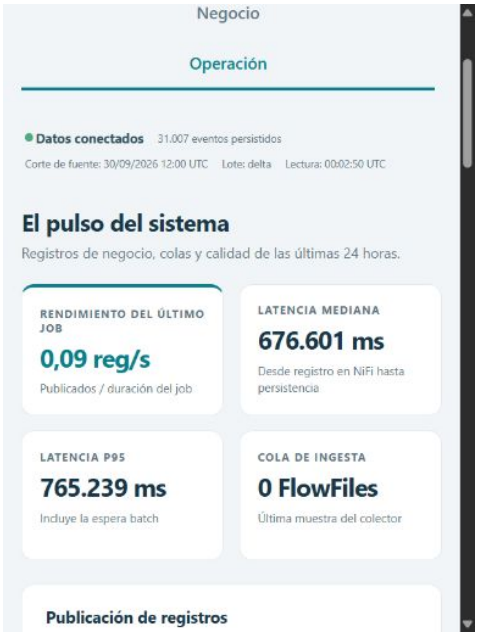
| Tipo de visualización | Pregunta |
|---|---|
| Líneas | ¿Cómo evoluciona el ingreso neto por canal? |
| Barras | ¿Qué categorías y productos tienen más unidades pagadas? |
| Mapa de calor | ¿En qué horas y días se confirman pagos? |
| Donut | ¿Cómo se reparte la participación de canales? |
| Dispersión | ¿Cómo se relacionan frecuencia y valor de clientes? |
| Histograma | ¿Cómo se distribuye el importe de los tickets? |

## Interactividad

Filtros de período, canal y categoría; navegación categoría → producto → pedido → historial de eventos. El panel lee PostgreSQL cada 15 segundos. BASE y DELTA permiten demostrar actualización con siete eventos nuevos y 280,00 BOB adicionales, conservando el estado de los hechos históricos.

La tabla de un producto presenta su subtotal; el historial presenta el pedido completo. La tasa de devolución del panel usa el último evento como corte, mientras Q5 usa 1 de octubre UTC; ambas muestran su corte para comparar cohortes correctamente.

# 6. Operación y aceptación




Panel operacional: métricas de las últimas 24 horas del laboratorio. Tiempo de negocio histórico y latencia de sistema tienen definiciones distintas.

## Métricas observadas

Throughput en registros por segundo de cada job, duración y resultado de intentos, latencia mediana/p95 desde el registro individual en NiFi hasta la persistencia y colas/errores. ingested_at se fija después de SplitJson: incluye validación, preparación/espera batch y procesamiento, y excluye la descarga HTTP y las colas anteriores. mtime es solo fallback documentado. Los pendientes se muestran separados de los rechazos.

| Control real | Resultado |
|---|---|
| Fuentes y API | Contrato, ciclo de pedidos y nueve verificaciones HTTP: PASS. |
| Negocio y transacción | Reglas financieras, rollback y repetición: PASS. |
| Spark real + JDBC | Lecturas, transformaciones, unión y publicación: PASS. |
| PostgreSQL completo | Conteos y todos los KPIs contra expected.json: PASS. |
| Dashboard | Callbacks, consultas, filtros, tipos de gráficos y detalle: PASS. |
| Backup / restauración | Ocho tablas y cifras financieras coincidentes: PASS. |

BASE: 31,000 hechos, neto 26.381.369,45 BOB. Final: 31,007 hechos, neto 26.381.649,45 BOB. La diferencia es exactamente el lote incremental previsto.

# 7. Correspondencia con la consigna

| Capa / peso | Implementación y evidencia |
|---|---|
| Ingesta · 20% | Apache NiFi; REST + CSV; contratos, cuarentena, limitación API, backpressure y manifiestos. |
| Procesamiento · 25% | Apache Spark batch; normalización, enriquecimiento, agregaciones y rutas de calidad/alto valor. |
| Almacenamiento · 20% | PostgreSQL particionado; índices, integridad transaccional y backup restaurado. |
| Análisis · 20% | Seis SQL con resultados y planes; primera ejecución y cinco repeticiones medidas. |
| Visualización · 15% | Negocio y operación; seis tipos de gráficos, filtros, detalle y actualización. |
| Opcionales | API FastAPI y Docker Compose suministrados. Docker no se ejecutó en este entorno. |

## Límites explícitos

Laboratorio local Windows con datos sintéticos y Spark local[2]. No se validaron contenedores en ejecución, escalado distribuido, replicación, ML, autenticación/RBAC de la API o de Dash ni despliegue público. No se atribuyen puntos extra por componentes no comprobados. El video es una demostración guiada construida con capturas y resultados reales; no se presenta como una grabación continua de streaming.

## Entrega

README.md es el índice. 01_Documentacion contiene este informe y el manual; 02_Codigo incluye fuentes y despliegue; 03_Visualizaciones contiene dashboards/capturas/evidencias; 04_Presentacion incluye slides y video. data conserva los insumos, lotes, resultados, manifiestos y respaldo. El ZIP incorpora un inventario SHA256 para verificar su integridad.

## Referencias oficiales

Apache NiFi: User Guide y backpressure
Apache Spark 4.0.1: SQL, JDBC y ejecución
PostgreSQL 17: particionamiento
PostgreSQL 17: pg_dump
Dash: actualización automática